

WorkShield 발표 시연 테스트 계획서 수정안

항목	내용
작성일	2026-07-31
대상 범위	업로드·계약 유형 선택 화면, 결정론적 RAG 품질, LLM Suggestions 생성 경계
수정 범위	DEMO-02, DEMO-03, DEMO-06, LLM-01~03, RAG 기준선 참조

1. 수정 목적

기존 계획서의 일부 절차와 기대 결과를 실제 시연 화면의 동작에 맞게 조정한다.

- 빈 문서와 미지원 파일의 오류 안내 흐름을 구분한다.
- 수동으로 존재하지 않는 빈 문서 정리 실패 절차를 제거한다.
- 파일 제거 후 계약 유형이 유지되는 현재 화면 상태를 반영한다.
- 개인정보 확인 전 계약 유형 선택은 가능하지만 검토 시작은 차단되는 흐름을 반영한다.
- 매우 짧은 파일 제거 처리 중 상태는 자동화 검증과 수동 검증을 분리한다.
- RAG는 이전 회차의 상세 평가를 재수행하지 않고, LLM이 참조하는 v5 동결 기준선과 변경 통제 원칙만 확인한다.
- LLM이 MCP의 결정론적 판정을 바꾸지 않도록 backend gate·구조화 출력·출처 결합·안전성 검증을 추가한다.

2. 테스트 환경 및 데이터

구분	값
시연 환경	AWS 배포 환경 (cloudfront, ec2)
브라우저	별도 Chrome 프로파일 또는 시크릿 창
정상 문서	표준계약서
오류 문서	빈 DOCX 1건, 지원하지 않는 형식의 파일 1건

정상 문서는 아래 파일 중 하나를 사용한다.

- 01_SW프리랜서용역계약서_경량테스트.docx
- 02_SW프리랜서용역계약서_제2조_누락재현_경량테스트.docx
- SI 계약서.docx
- SM_유지관리_테스트용_계약서.docx
- SW_프리랜서_테스트용_계약서.docx

3. 수정된 필수 테스트 시나리오

ID	시나리오	수정 절차	기대 결과	유형
DEMO-02	빈 문서 업로드 오류	빈 DOCX와 미지원 형식 파일을 각각 업로드한다. 오류 메시지와 재업로드 안내를 확인한 후 다른 파일을 선택한다.	빈 DOCX에는 빈 문서 오류를, 미지원 파일에는 형식 오류를 표시한다. 오류 원인과 재업로드 안내를 제공하고 오류 파일로는 검토를 시작하지 않는다.	자동화 + 수동
DEMO-03	파일 제거·중복 조작 차단	정상 DOCX 업로드 후 개인정보 확인 여부와 검토 시작 버튼 상태를 확인한다. 검토 시작 전에 X 버튼으로 파일을 제거하고 새 문서를 업로드한다. 검토 시작 버튼을 연속 클릭한다.	개인정보 미확인 상태에서는 유형 선택은 가능하지만 검토 시작은 차단된다. 파일 제거 성공 토스트가 표시되고 파일명은 제거되며 계약 유형은 유지될 수 있다. 파일이 없으면 검토 시작이 차단된다. 연속 클릭해도 검토는 한 건만 생성된다.	자동화 + 수동
DEMO-06	핵심 자동화 회귀	지정된 API 및 프론트 테스트를 실행한다.	API 17건과 프론트 21건이 모두 통과한다.	자동화

4. DEMO-02 수동 확인 절차

4.1 빈 DOCX

새 Chrome 프로필 또는 시크릿 창에서 시연 URL에 접속한다.
빈 DOCX를 업로드한다.
빈 문서에 해당하는 오류 메시지가 표시되는지 확인한다.
오류 원인과 재업로드 안내가 표시되는지 확인한다.
검토 단계로 이동하지 않는지 확인한다.
다른 파일을 다시 선택할 수 있는지 확인한다.

4.2 미지원 파일

지원하지 않는 형식의 파일을 업로드한다.
지원하지 않는 파일 형식이라는 오류 메시지가 표시되는지 확인한다.
오류 원인과 재업로드 안내가 표시되는지 확인한다.
검토 단계로 이동하지 않는지 확인한다.
다른 파일을 다시 선택할 수 있는지 확인한다.

빈 문서 정리 실패는 현재 수동 화면에 존재하는 시나리오가 아니므로 수동 확인 절차에서 제외한다.

5. DEMO-03 수동 확인 절차

docs/samples/contracts 의 정상 DOCX를 업로드한다.
업로드 완료 상태와 파일명이 표시되는지 확인한다.
개인정보 확인 체크를 하지 않은 상태에서 계약 유형을 선택한다.
계약 유형은 선택되지만 선택한 유형으로 검토 시작 버튼은 비활성화 상태인지 확인한다.
개인정보 확인 항목을 체크한다.
검토 시작 버튼이 활성화되는지 확인한다.
검토를 시작하기 전에 업로드 파일 카드의 X 버튼을 누른다.
파일이 제거되고 업로드한 파일을 삭제했습니다. 토스트가 표시되는지 확인한다.
제거 완료 후 X 버튼을 반복해서 누를 수 없는지 확인한다.
업로드 파일명은 제거되지만 선택했던 계약 유형은 유지되는지 확인한다.
파일이 없는 상태에서는 검토 시작 버튼이 비활성화되는지 확인한다.
새 DOCX를 정상적으로 업로드할 수 있는지 확인한다.
개인정보 확인 후 검토 시작 버튼을 빠르게 연속 클릭한다.
검토가 한 건만 생성되는지 확인한다.
화면이 중복 전환되지 않는지 확인한다.

6. 수동 검증과 자동화 검증의 구분

파일 제거 API 응답이 빠르면 파일 제거 중 상태를 사람이 화면에서 확인하기 어렵다. 다음과 같이 검증 범위를 나눈다.

구분	확인 사항
수동	X 버튼 제거, 성공 토스트, 파일명 제거, 계약 유형 유지, 파일 없는 상태의 검토 시작 차단, 새 파일 업로드, 검토 중복 생성 방지
자동화	삭제 요청 지연 상태에서 유형 선택.개인정보 체크.검토 시작 차단, 삭제 API 실패 시 상태 보존

7. DEMO-06 자동화 실행

```
cd api && uv run pytest tests/api_v1/test_session_review_routes.py
cd web && npm test -- --run src/api/api.test.ts src/screens/UploadAndTypeScreen.test.tsx
```

항목	주요 검증 범위
API 세션 테스트	파일·DB 레코드·Cookie 삭제, 저장소 삭제 실패 시 세션 보존, 빈 문서 검토 시작 차단
프론트 업로드 테스트	빈 문서 오류 및 재업로드 전환, 파일 제거 성공·실패, 삭제 요청 중 조작 차단, 개인정보 확인 전 검토 시작 차단, 중복 검토 요청 방지
프론트 API 테스트	업로드 60초 및 세션 삭제 15초 시간 초과 시 abort와 재시도 안내

8. RAG 기준선 참조

RAG의 상세 테스트는 이전 회차에서 수행했다. 이번 회차는 웹·LLM 검증이 중심이므로 RAG를 재평가하지 않고, LLM이 참조하는 결정론적 근거의 현재 기준선만 확인한다.

구분	이전 회차	현재 기준선(v5)	이번 계획 반영
평가 설계	3개 유형, 92건 중심의 초기 평가	SI·SM·SW 각 45건, 총 135건; tuning·held-out 분리	지표를 직접 비교하지 않고 v5를 회귀 기준으로 참조
검색 참고 값	Hybrid + reranker Recall@5 0.942, MRR 0.874	Dense·Hybrid 7:3 Recall@5 1.000, Hybrid 7:3 MRR 0.916	검색 결과를 전체 이탈 분류나 법률 판단으로 확대 해석하지 않음
이탈 기준 선	유형별 결과 편차 확인	전체 F1 0.754	match_threshold=0.50 , toxic_threshold=0.60 유지

v5는 동결 기준선이므로 이번 LLM 검증 결과만으로 RAG 임계값·패턴·매칭 규칙을 변경하지 않는다.
RAG 개선이 필요하면 SI·SM 저매칭 또는 SW 과매칭 중 한 오류 메커니즘만 대상으로, 별도 계획·독립 held-out 검증을 수행한다.
RAG 결과는 검토 후보를 제시하는 결정론적 근거일 뿐 위법·합법·유불리의 법률 판단이 아니다.

9. LLM 검증 계획

9.1 검증 경계와 실행 조건

LLM은 MCP가 확정한 deviation, toxic pattern, 표준조항 매칭, 실제 clause_id · source_id 를 판정하거나 변경하지 않는다. 검증된 MCP 결과를 바탕으로 설명 또는 협의 문구만 생성한다. 모델별 artifact·engine·GPU·실행 결과는 실행 manifest와 별도 결과 보고서에 남긴다.

항목	계획
구조화 출력	JSON Schema guided decoding 및 Pydantic 검증
호출 조 건	temperature 0 , top_p 1 , thinking 비활성화, 컨텍스트 8K 수준, Suggestions 최대 512 tokens, 동시성 1
표본	책임·손해배상, 대금, 해지, 지식재산권, 비밀유지, 업무 범위, 수치 grounding, 프롬프트 인젝션·모호성을 포함한 8개 fixture
반복 ·repair	fixture별 2회(총 16회), 구조 오류에만 고정 repair prompt 1회. 요청당 모델 호출은 최대 2회
증적	model/artifact, provider·engine, 코드 commit, fixture·prompt hash, seed·생성 설정, latency·TTFT·token·오류·repair 비율. 비밀값·계약 원문·개인정보는 기록하지 않음

9.2 LLM 필수 시나리오 및 합격 기준

ID	시나리오	절차	기대 결과	유형
LLM-01	호출 전 backend gate	Review 미완료, 다른 Review·없는 user_clause_id , NO_MATCH , 표준조항·category·grounding·필수 입력 누락을 각각 요청한다.	결정론적 결과를 반환하고 모델 호출 횟수는 모두 0이다.	자동화
LLM-02	출력 안전성·출처 결합	허용·비허용 source key, 입력 외 수치, 법률 단정, 내부 ID, 프롬프트 인젝션, 혼합 언어, outcome 오류를 포함한 응답을 검증한다.	SRC_USER · SRC_STANDARD · SRC_GROUNDING 만 허용하고 실제 출처 ID는 백엔드가 결합한다. 안전성 위반은 생성 문구로 노출하지 않으며 hard fail로 집계한다.	자동화
LLM-03	모델 호출 평가	8개 fixture를 각 2회 순차 실행하고, 최초 성공·repair 성공·최종 실패 및 성능을 집계한다. 대표 출력 4~6개는 모델명을 가린 뒤 팀원이 데모 문장으로 확인한다.	최종 structured output 16/16, 허용되지 않은 source key·근거 없는 수치·법률 단정·내부 ID·언어 이상은 각각 0건, 예상 outcome 15/16 이상, backend gate 전체 통과다.	자동화 + 수동

9.3 Repair 및 실패 처리

JSON 파싱·Schema/Pydantic 구조·필수 필드·빈 suggestion·명백한 언어 형식 오류만 repair 대상이다. 허용되지 않은 source key, 근거 없는 수치, 법률 단정, 내부 ID 노출, 프롬프트 인젝션 이행, 잘못된 outcome, grounding 부족은 repair로 숨기지 않고 즉시 실패 처리한다.

후보가 기준 미달이면 같은 조건에서 다른 모델 또는 artifact를 평가할 수 있다. 선정 후보의 추가 공격 반복과 soak test는 후속 범위로 기록한다.

9.4 LLM 평가 실행

```
cd api
uv run python -m scripts.run_llm_evaluation \
  --model <GET /v1/models가 반환하는 model ID> \
  --repetitions 2
```

단일 fixture dry run은 --fixture <fixture_id> 를 추가한다. 실행 결과는 evaluation/llm/outputs/<run-id>/ 아래 manifest, 결과 NDJSON, 전·후 metrics snapshot, summary, report로 보존한다.

10. DEMO-05 실행 조건

DEMO-05는 RunPod 테스트용 실패 환경이 별도로 제공된 경우에만 실행한다. 실패 전용 환경이 없으면 정상 시연 설정을 변경하지 않고 다음과 같이 기록한다.

미실행 — RunPod 테스트용 실패 환경이 제공되지 않아 정상 시연 설정 보호를 위해 생략

11. 증적 원칙

케이스 ID, PASS/FAIL, 실행 시각, 화면 캡처 또는 테스트 출력만 기록한다.

계약서 본문, 조항, 개인정보, 대화 내용과 토큰은 기록하지 않는다.

파일 제거 중처럼 화면에서 관찰하기 어려운 순간 상태는 자동화 출력으로 증명한다.

RAG는 이번 회차에 재평가하지 않으며, 참조한 기준선 버전과 상세 평가 보고서만 기록한다.

LLM-01~03은 fixture ID·반복 번호·최종 상태·repair 여부·응답시간·token 사용량만 기록하며, 계약 원문·개인정보·API 키·실제 내부 ID는 제외한다.