

WorkShield 테스트 결과보고서

항목	내용
작성일	2026-07-31
대상 커밋	웹 시연 검증 e63236d / LLM 평가는 실행별 manifest 기준
테스트 기간	2026-07-28 ~ 2026-07-31
대상 범위	업로드·계약 유형 선택 화면, LLM Suggestions 생성 경계, 결정론적 RAG 기준선 비교
종합 판정	조건부 승인

1. 요약

이번 검증에서는 시연 화면의 업로드·파일 제거·중복 요청 방지와 LLM Suggestions 생성 안전성을 우선 확인했다. 수동 및 자동화 시연 케이스는 실행한 3건이 모두 통과했고, RunPod 실패 안내 케이스는 분리된 실패 환경이 없어 미실행으로 남았다. LLM 후보 3종 중 RedHatAI/Qwen3.5-9B-FP8-dynamic 만 전체 기준을 충족해 데모 운영 후보로 유지한다.

영역	계획/대상	결과	판정
시연 화면	DEMO-02, 03, 05, 06	3건 PASS, 1건 미실행	조건부 승인
LLM 후보	Qwen 9B, EXAONE 7.8B, Gemma 12B	Qwen 16/16 PASS, 나머지 기준 미달	Qwen 채택 유지
RAG	v5 결정론적 기준선	135건 기준선 및 한계 확인	이전 회차 대비 기준선 만 인용

조건부 승인 사유는 기능 실패가 아니라 DEMO-05를 검증할 전용 RunPod 실패 환경이 제공되지 않았기 때문이다. 실패 환경이 제공되면 오류 안내와 재시도 흐름을 추가 검증해야 한다.

2. 대상 및 환경

구분	값
시연 환경	AWS (cloudfront, ec2)
브라우저	별도 Chrome 프로필 또는 시크릿 창
웹 테스트 데이터	표준계약서
LLM provider-engine	vLLM 0.26.0
LLM 실행 환경	NVIDIA A40 1장, 동시성 1, temperature 0 , top_p 1 , seed 42 , thinking OFF
LLM 평가 데이터	v5 SW fixture를 참조한 8개 overlay fixture, 각 2회(총 16회)
LLM 실행 상한	평가 시 completion token 1000 ; 운영 Suggestions 상한은 512 유지 권고

LLM 실행에 사용한 컨테이너 image는 vllm/vllm-openai:latest 였으며, model revision-tokenizer hash-image digest가 고정되지 않은 한계가 있다. 이후 재실행·배포에서는 이를 고정해 재현성을 높여야 한다.

3. 시연 화면 테스트 결과

3.1 결과 요약

항목	결과
계획 케이스	4
실행 케이스	3
PASS / FAIL / BLOCKED	3 / 0 / 0
미실행	1
실행 케이스 통과율	100%
전체 계획 완료율	75%

3.2 케이스별 결과

ID	시나리오	실제 결과	판정
DEMO-02	빈 문서·업로드 오류	빈 DOCX와 미지원 형식 파일에 서로 구분되는 오류 메시지, 실패 원인 및 재업로드 안내가 표시됐다. 오류 파일로 검토가 시작되지 않았고 다른 파일을 선택할 수 있었다.	PASS
DEMO-03	파일 제거·중복 조작 차단	파일 제거 토스트와 파일명 초기화가 확인됐다. 선택한 계약 유형은 유지됐지만 파일이 없으면 검토 시작은 비활성화됐다. 새 문서 업로드 후 연속 클릭해도 검토는 한 건만 생성되고 화면이 중복 전환되지 않았다.	PASS
DEMO-05	RunPod 오류 안내	테스트용 실패 환경이 제공되지 않아 정상 시연 환경 보호 원칙에 따라 실행하지 않았다.	미실행
DEMO-06	핵심 자동화 회귀	API 17건 및 프론트엔드 21건이 모두 통과했다.	PASS

3.3 주요 확인 사항

- 개인정보 확인 전에도 계약 유형 선택은 가능하지만, 검토 시작은 차단됐다.
- 파일 제거 후 파일 카드와 X 버튼이 사라져 반복 제거 조작이 불가능했다.
- 파일 제거 API 응답이 빨라 파일 제거 중 상태를 수동으로 관찰하기 어려웠다. 삭제 요청 중 조작 차단은 자동화 테스트 결과로 확인하는 것이 적절하다.
- 빈 문서 정리 실패는 현재 수동 화면 흐름에 존재하지 않아 결과 대상에서 제외했다.

3.4 자동화 실행 결과

구분	실행 명령	결과
API	cd api && uv run pytest tests/api_v1/test_session_review_routes.py	17 passed, 7.80초
프론트엔드	cd web && npm test -- --run src/api/api.test.ts src/screens/UploadAndTypeScreen.test.tsx	2 files / 21 passed, 7.19초

자동화 범위에는 파일·DB 레코드·Cookie 삭제, 저장소 삭제 실패 시 세션 보존, 빈 문서 검토 시작 차단, 업로드 오류·재업로드, 제거 성공·실패, 삭제 요청 중 조작 차단, 개인정보 확인 전 차단, 중복 검토 요청 방지가 포함된다.

4. LLM 검증 결과

4.1 공통 합격 기준

각 후보는 책임·대금·해지·지식재산권·비밀유지·업무 범위·수치 grounding·프롬프트 인젝션의 8개 fixture를 2회씩 실행했다. 최종 structured output 16/16, 예상 outcome 15/16 이상, backend gate 전체 통과가 기본 기준이며 허용되지 않은 source key, 근거 없는 수치, 법률 단정, 실제 내부 ID 노출, 언어 이상은 각각 0건이어야 한다.

LLM은 MCP의 deviation, toxic pattern, 표준조항 매칭 및 실제 내부 ID를 판정·변경하지 않고, 검증된 결과를 바탕으로 협의 문구만 생성한다. 구조·언어 형식 오류에만 고정 repair를 최대 1회 적용하고, 안전성 위반은 repair로 숨기지 않고 실패 처리한다.

4.2 후보 비교

후보	최종 결과	주요 관측	운영 판단
RedHatAI/Qwen3.5-9B-FP8-dynamic	16/16 PASS	hard gate 실패 0, repair 2회 후 최종 안전성 기준 충족, p50 7.102초 / p95 16.416초	채택 유지
LGAI-EXAONE/EXAONE-3.5-7.8B-Instruct-AWQ	2/16 PASS	14건이 1000 token에서 length 종료되어 유효 structured output을 만들지 못함, p50 17.433초	미채택
RedHatAI/gemma-4-12B-it-FP8-Dynamic	12/16 PASS	지금 fixture 2건이 60초 timeout, 책임 fixture 2건의 필수 용어 미반영, n 줄바꿈 오염, p50 24.888초 / p95 60.042초	미채택

4.3 선정 후보: Qwen 9B

Qwen 9B는 16개 최종 응답 모두 JSON Schema 및 Pydantic 검증을 통과했다. 허용되지 않은 source key, 근거 없는 수치, 법률 단정, 실제 내부 ID 노출, 최종 중국어·러시아어 문자, 프롬프트 인젝션 이행은 모두 0건이었다. 수치 fixture는 제공된 30일을 사용했으며 새로운 수치를 생성하지 않았다.

손해배상 fixture 2건의 최초 응답에는 중국어 免責 가 포함됐으나, 언어 hard gate가 이를 감지해 고정 repair를 1회씩 실행했다. 최종 응답은 모두 정상화됐고 요청당 최대 2회라는 호출 상한을 지켰다. 따라서 언어 hard gate와 구조·언어 오류 한정 repair는 운영에서도 유지한다.

성능 지표	결과
실제 모델 호출	18회 (평가 16회 + repair 2회)
finish_reason=stop	18/18
전체 latency p50 / p95 / 최대	7.102초 / 16.416초 / 16.416초
평균 TTFT	0.367초
생성 토큰 합계	3,072
completion token p50 / p95 / 최대	165 / 255 / 255

1000-token 평가에서도 최대 생성량은 255 tokens였으므로, 데모 운영에서는 비용과 응답시간을 통제하기 위해 Suggestions의 max_completion_tokens 를 512로 유지한다. 이 결과는 제한된 fixture의 생성 적합성 결과이며 법률 전문가 검토나 실제 사용 환경의 실패율 0%를 의미하지 않는다.

4.4 제외 후보와 fail-closed 확인

EXAONE은 책임 fixture dry-run 2/2를 통과했지만, 전체 평가에서는 나머지 14건이 구조화 응답을 종료하지 못했다. 불완전 응답은 모두 LLM_OUTPUT_INVALID 로 차단됐으며, 부분 응답을 사용자에게 노출하거나 이어 쓰기 repair를 하지 않은 fail-closed 동작은 정상이다.

Gemma는 1000-token 상한으로 이전 512-token 평가의 11/16에서 12/16으로 한 건 늘었지만, 지금 fixture의 timeout 2건으로 hard gate를 통과하지 못했다. 상한 증가는 길이 종료 일부를 해소했지만 p95 latency를 60.042초까지 높였으므로, token 상한을 더 늘려 해결하지 않는다.

두 후보는 모델별 예외로 합격 기준을 낮추지 않는다. 재평가가 필요하면 chat template-schema 길이 제약·간결한 출력 지시 등 원인을 하나씩 분리해 수정한 뒤, 책임 외 지금·해지 fixture를 포함한 dry-run과 동일한 16회 기준을 다시 적용한다.

5. RAG 기준선 비교

RAG는 이전 회차에 이미 별도 계획·결과 보고서로 상세 검증했으므로, 이번 보고서에서는 LLM이 참조하는 결정론적 근거의 현재 기준선만 비교한다. 이전 회차의 92건 평가와 현재 v5의 135건 평가는 데이터 구성·정답 정의·목적이 달라 지표를 직접적인 성능 상승 또는 하락으로 해석하지 않는다.

구분	이전 회차	현재 기준선(v5)	이번 반영
평가 규모· 설계	3개 유형, 92건 중심의 초기 검색·이탈·독소 평 가	SI·SM·SW 각 45건, 총 135건; tuning 30 건과 held-out 15건을 유형별로 분리	비교 가능한 회귀 기 준과 정보 누출 방지 절차를 강화
검색 결과	Hybrid + reranker Recall@5 0.942, MRR 0.874	Dense·Hybrid 7:3 Recall@5 1.000, Hybrid 7:3 MRR 0.916 (정답 표준조항이 있는 45건 기준)	검색 수치를 전체 이 탈 분류 성능으로 확 대 해석하지 않음
이탈 기준 선	초기 데이터에서 유형 별 결과 편차 확인	전체 정밀도 0.742, 재현율 0.767, 특이도 0.467, F1 0.754	현재 기준은 동결하 며, 임계값을 결과만 으로 변경하지 않음

현재 기본값은 `match_threshold=0.50` , `toxic_threshold=0.60` 이다. SI·SM은 정상 조항을 이탈로 경고하는 저매칭 경향이, SW는 표준에 없는 조항을 표준에 연결해 놓치는 과매칭 경향이 남아 있다. 따라서 하나의 전역 임계값 조정으로 문제를 해결했다고 판단하지 않으며, 후속 변경은 오류 메커니즘 하나·사전 통과 기준·독립 held-out 검증을 갖춘 별도 실험으로 제한한다.

RAG 결과는 표준 대비 검토 후보를 제시하는 결정론적 근거이며, 위법·합법·유불리의 법률 판단이나 LLM 생성 결과의 정확성 보증이 아니다.

6. 결함·위험 및 조치 현황

ID	구분	심 각 도	내용	상태 및 조치
RSK-01	테스트 공백	중 간	RunPod 실패 전용 환경 부재로 DEMO-05 오류·재시도 흐름을 실행하지 못함	미해결. 정상 시연 환경과 분리된 실패 환경 제공 후 재검증
RSK-02	LLM 출 력 품질	낮 음	Qwen 최초 응답 2건에서 중국어 혼입 관측	완화됨. 언어 hard gate와 최대 1회 repair 유지
RSK-03	재현성	중 간	LLM model revision·tokenizer hash·container image digest 미고정	미해결. 다음 배포부터 manifest 및 image digest 고정
RSK-04	후보 안 정성	중 간	EXAONE 구조화 출력 종료 실패, Gemma timeout·형식 오류	조치 완료. 두 후보는 운영 대상에서 제외하고 Qwen 유지

시연 화면에서 확인된 기능 결함은 없다. 기존 계획서와 UI 간 문서 해석 차이는 파일 제거 후 계약 유형 유지와 수동 관찰이 어려운 제거 중 상태였으며, 수정된 계획서에 반영했다.

7. 정책·보안 확인

확인 항목	결과	근거
오류 파일의 검토 시작 차단 및 재업로드 안내	PASS	DEMO-02 수동 검증
개인정보 확인 전 검토 시작 차단	PASS	DEMO-03 수동 검증 및 프론트 자동화
파일 제거 후 중복 조작·중복 검토 생성 방지	PASS	DEMO-03 및 프론트 자동화
LLM 호출 전 불완전 조건 차단	PASS	공통 LLM backend gate 기준
허용 source key·수치·법률 단정·내부 ID 안전성 gate	PASS (Qwen)	Qwen 16/16 결과
구조화 실패 응답의 사용자 노출 차단	PASS	EXAONE LLM_OUTPUT_INVALID 차단 결과
RAG 결과를 법률 판단으로 단정하지 않음	PASS	v5 품질 기준선의 적용 범위

8. 결론 및 후속 조치

최종 판정은 **조건부 승인**이다. 시연 핵심 흐름과 자동화 회귀는 통과했고, Qwen 9B는 정해진 LLM 안전성·구조화 출력·성능 기준을 충족했다. 다만 DEMO-05의 오류·재시도 안내는 아직 실제 실패 환경에서 검증되지 않았다.

시연 전에는 Qwen의 thinking OFF, JSON Schema structured output, 언어·수치·법률 단정·내부 ID hard gate, 구조·언어 오류 한정 최대 1회 repair, Suggestions 512-token 상한을 유지한다. LLM timeout과 repair 비율은 운영 중에도 관측한다.

후속 조치는 다음과 같다.

- RunPod 실패 전용 환경에서 DEMO-05를 실행하고 오류 문구, 성공 화면 오인 방지, 재시도 안내를 증적으로 남긴다.
- 배포 manifest에 model revision, tokenizer/chat template hash, image digest를 고정한다.
- Qwen 선정 후 추가 공격 반복과 soak test는 별도 범위로 수행한다.
- RAG 개선은 v5 동결 기준선을 변경하지 않고, SI·SM 저매칭 또는 SW 과매칭 중 하나를 독립 실험으로 검증한다.

비고

증적에는 계약서 본문, 조항, 개인정보, 대화 내용, API 키 및 실제 내부 ID를 포함하지 않는다.

전문적인 AI 아티팩트 PDF 변환 엔진 - md2pdf.cc